

volet B: Data Analyste

1. Preparation de donnees

releves_consommation.csv:

- 512 986 lignes
- 4 colonnes :
 - id_pdl (identifiant)
 - date
 - consommation_kwh (valeurs numériques)
 - zone

consommation_kwh → 6856 valeurs manquantes

actifs_si.csv:

- 28 actifs informatiques
- 7 colonnes
 - id_actif
 - nom
 - type
 - criticite
 - exposition
 - proprietaire
 - donnees_sensibles

aucune valeurs manquantes

cas_fraude_confirmes.csv:

- 24 cas de fraude
- 4 colonnes :
 - id_pdl → identifiant client/point de livraison
 - date_detection → date de détection
 - type_fraude → type de fraude
 - statut → ici tous confirmée

aucune valeur manquante

clients.csv:

- 700 clients
- 7 colonnes :
 - id_client
 - segment (particulier / pro)
 - commune
 - code_postal
 - date_entree
 - nb_personnes_foyer
 - surface_m2

nb_personnes_foyer → 274 valeurs manquantes

compteurs.csv:

- 700 compteurs

- 9 colonnes :
 - id_pdl → point de livraison
 - id_client
 - zone
 - type_client
 - puissance_souscrire_kva
 - type_chauffage
 - type_compteur
 - date_pose
 - statut

aucune valeur manquante

incidents_reseau.csv:

- 420 incidents réseau
- 7 colonnes :
 - id_incident
 - date_debut
 - duree_minutes
 - zone
 - type
 - nb_pdl_impactes
 - cause

aucune valeur manquante

journaux_securite.csv:

- 47 824 événements de sécurité
- 6 colonnes :
 - horodatage → moment de l'événement
 - utilisateur → utilisateur concerné
 - source_ip → adresse IP
 - systeme → application / système
 - type_evenement → type d'action
 - resultat → succès / échec

aucune valeur manquante

meteo.csv:

- 5 848 lignes
- 5 colonnes :
 - date
 - zone
 - temp_moyenne_c
 - temp_min_c
 - temp_max_c

aucune valeur manquante

reclamations.csv:

- 3000 réclamations
- 6 colonnes :

- id_reclamation
- id_client
- date
- canal (téléphone, email, agence, etc.)
- texte (description de la plainte)
- satisfaction

aucune valeur manquante

relevés_horaires_echantillon.csv

- 21 600 lignes
- 4 colonnes :
 - id_pdl → point de livraison
 - horodatage → heure précise (pas seulement date)
 - consommation_kwh → consommation horaire
 - zone → localisation

aucune valeur manquante

Résumé des tables

	table	nb_lignes	valeurs_manquantes
0	actifs_si.csv	28	0
1	cas_fraude_confirmes.csv	24	0
2	clients.csv	700	274
3	compteurs.csv	700	0
4	incidents_reseau.csv	420	0
5	journaux_securite.csv	47824	0
6	meteo.csv	5848	0
7	reclamations.csv	3000	0
8	relevés_consommation.csv	512986	6856
9	relevés_horaires_echantillon.csv	21600	0

- Nettoyage des données:
 - supprimer doublons
 - gérer valeurs manquantes
 - corriger formats dates
 - filtrer valeurs aberrantes

Tables avec données propres:

```
actifs_si.csv nettoyé → clean_actifs_si.csv | lignes finales: 28
cas_fraude_confirmer.csv nettoyé → clean_cas_fraude_confirmer.csv | lignes
finales: 24
clients.csv nettoyé → clean_clients.csv | lignes finales: 426
compteurs.csv nettoyé → clean_compteurs.csv | lignes finales: 653
incidents_reseau.csv nettoyé → clean_incidents_reseau.csv | lignes finales:
418
journaux_securite.csv nettoyé → clean_journaux_securite.csv | lignes finale
s: 47824
meteo.csv nettoyé → clean_meteo.csv | lignes finales: 5848
reclamations.csv nettoyé → clean_reclamations.csv | lignes finales: 3000
releves_consommation.csv nettoyé → clean_releves_consommation.csv | lignes
finales: 495177
releves_horaires_echantillon.csv nettoyé → clean_releves_horaires_echantill
on.csv | lignes finales: 20743
```

2. Analyses

- Consommation totale par client

TOP 10 CLIENTS LES PLUS CONSOMMATEURS :

id_pdl	
PDL-000221	448779.34
PDL-000162	446379.61
PDL-000240	432940.04
PDL-000103	432292.71
PDL-000268	428544.82
PDL-000031	426823.07
PDL-000600	425664.25
PDL-000141	420059.47
PDL-000548	409482.42
PDL-000069	408589.24

Les 10 premiers clients ont des consommations très élevées et relativement proches entre eux :

- Maximum : 448 779 kWh (PDL-000221)
- Minimum du top 10 : 408 589 kWh (PDL-000069)
- Écart total dans le top 10 : ~40 000 kWh
- profil moyen de consommation

	mean	std	min	max
id_pdl				
PDL-000001	12.701295	17.273965	6.31	289.35
PDL-000002	12.741446	5.992560	7.75	118.68
PDL-000003	17.345596	20.163896	0.00	413.00
PDL-000004	74.762236	46.610874	30.21	744.03
PDL-000005	12.544189	9.060162	6.35	193.20

Trois types de comportements apparaissent :

1. consommateurs stables

PDL-000002, PDL-000005

faible std

usage régulier

2. consommateurs variables

PDL-000001, PDL-000003

std élevé

pics de consommation

3. gros consommateur atypique


PDL-000004

très forte moyenne et très forte variabilité

- segmentation simple (faible / moyen / fort)

segment_consommation	
faible	256965
moyen	125975
fort	111232
Name: count, dtype: int64	

- saisonnalité



 CONSOMMATION MOYENNE PAR SAISON :

saison	
automne	58.142989
hiver	64.179551
printemps	58.701081
été	54.755452

hiver = saison la plus énergivore

été = saison la plus économique

printemps/automne = stabilité intermédiaire


correlation meteo:

corr=0.87




- Relation linéaire entre température et consommation
- la température peut expliquer la variation de consommation
- segmentation par zone:


	zone	consommation_totale_kwh
0	Bourg-Ancien	2664762.74
1	Centre-Ville	4236914.33
2	Coteaux-Ouest	1029038.05
3	Parc-Tertiaire	5192483.03
4	Plateau-Est	809162.05
5	Rives-Sud	2641193.72
6	Val-Nord	1232999.67
7	Zone-Industrielle	11309302.11

3. Dashboard:



Consommation par mois





4. Rapport d'analyse et recommandations métier

- Analyse des données

L'analyse des données de consommation énergétique met en évidence des variations importantes selon les zones géographiques, les types de clients et les conditions météorologiques.

La consommation est principalement portée par les clients résidentiels, tandis que les clients professionnels présentent des consommations plus stables mais parfois élevées.

Une saisonnalité est observée : la consommation augmente lorsque les températures diminuent, indiquant un impact direct de la météo sur la demande énergétique.

Enfin, certains points de livraison présentent des consommations anormalement élevées, pouvant indiquer des comportements atypiques ou des anomalies.

- Enseignements principaux

Les résultats montrent que la consommation énergétique dépend de plusieurs facteurs combinés : la météo, le type de client et la zone géographique.

Le réseau présente donc des profils de consommation hétérogènes, avec des pics localisés et des variations saisonnières marquées.

- Recommandations

- Adapter la capacité du réseau selon les zones à forte consommation.
- Améliorer la segmentation des clients pour mieux comprendre les usages.
- Surveiller les consommations anormales pour détecter des anomalies.
- Utiliser les données météo pour améliorer la prévision de la demande.

Volet E : Cybersécurité et Infrastructures Critiques

1. Analyse de risques

Cartographie des actifs

Les principaux actifs du système Néovolt sont :

- Données de consommation énergétique (kWh)
- Données clients (identité, zone, segment)
- Compteurs connectés (id_pdl)
- Plateforme d'analyse (Python, Power BI)
- Fichiers de stockage (CSV / base de données)

Menaces identifiées

- Vol ou fuite de données personnelles
- Modification frauduleuse des données de consommation
- Accès non autorisé aux systèmes
- Panne ou indisponibilité de la plateforme
- Attaques sur les compteurs connectés (IoT)

Vulnérabilités

- Données stockées en fichiers CSV non chiffrés
- Absence de contrôle d'accès fort
- Manque de journalisation des actions
- Communication non sécurisée entre composants
- Dépendance à des scripts locaux non protégés

Scénarios d'attaque

- Injection ou modification de données de consommation pour masquer une fraude
- Accès non autorisé à des fichiers clients
- Exploitation des compteurs pour falsifier les relevés
- Interruption du service d'analyse (attaque sur disponibilité)

Criticité

- Données clients → critique
- Compteurs → critique
- Plateforme d'analyse → élevée
- Visualisation (Power BI) → moyenne

2. Audit de sécurité

Une revue de sécurité du prototype montre plusieurs faiblesses :

- stockage des données en clair (CSV)
- absence d'authentification utilisateur
- absence de chiffrement des données sensibles
- absence de traçabilité (logs)
- accès global aux fichiers sans restriction

Recommandations priorisées

Priorité haute

- Mise en place d'un contrôle d'accès (rôles utilisateurs)
- Chiffrement des données sensibles
- Protection des données clients

Priorité moyenne

- Mise en place de logs d'activité
- Validation des données à l'entrée

Priorité basse

- Amélioration de la structure de stockage
- Séparation des environnements (test / production)

3. Sécurisation de la chaîne (DevSecOps)

La sécurité est intégrée dans tout le cycle de développement :

Développement

- validation des données (suppression des anomalies)
- contrôle de cohérence des datasets

Gestion des identités

- rôles définis :
 - administrateur
 - analyste
 - utilisateur limité

Sécurisation des communications

- utilisation de protocoles sécurisés (HTTPS/TLS)
- chiffrement des données des compteurs connectés
- authentification des dispositifs IoT

4. Détection et réponse (SIEM / SOC)

Plan de supervision

Un système de supervision centralisé permet de surveiller :

- connexions utilisateurs
- accès aux données sensibles
- anomalies de consommation
- comportements suspects

Règles de détection

- multiples tentatives de connexion échouées
- variation brutale de consommation
- accès simultané anormal à plusieurs fichiers
- modification inattendue de données historiques

Runbook de réponse à incident

1. Détection de l'incident via logs
2. Isolation du compte ou système concerné
3. Analyse de la cause
4. Correction de la vulnérabilité
5. Restauration des services
6. Documentation de l'incident

5. Continuité et conformité

Continuité (PCA / PRA)

- sauvegardes régulières des données
- restauration rapide des datasets
- duplication des environnements critiques

Conformité RGPD

- minimisation des données collectées
- protection des données personnelles
- anonymisation des identifiants clients
- limitation des accès aux données sensibles