

Examen de fin de second semestre — Juin 2026

PROJET

NÉOVOLT GRID+

Fait par :

- Rania Chahinez MERZOUGUI
 - Kahina BRAHIMI
 - Cylia AIRA
 - So
 - Sonia LASKRI
-

Executive Summary

Néovolt is a regional energy distributor serving approximately 600,000 residential and professional customers across a mixed urban-rural territory. Over the past two years, the company has deployed smart meters (communicating devices) that generate half-hourly readings — amounting to nearly 513,000 daily data points from 700 active metering points in our dataset. Despite this data richness, consumption data remains under-exploited, poorly centralised, and of uneven quality.

The Néovolt Grid+ programme is designed to address four critical business problems:

- Poorly anticipated consumption peaks, leading to costly last-minute energy purchases on spot markets.
- Delayed detection of anomalies and meter fraud — confirmed cases exist (25 validated fraud cases in the dataset) but detection is reactive, sometimes months late.
- Absence of actionable dashboards for network operations, customer relations, and financial management teams.
- An unaudited security posture across smart meters, the data platform, and critical infrastructure, at a time of tightening regulation (GDPR, NIS2, critical infrastructure directives).

Our team has been commissioned by Néovolt's CIO to deliver, in a one-week sprint, a credible prototype and a decision-support dossier covering data engineering, predictive analytics, data visualisation, cybersecurity, and programme management.

Key outputs of this sprint include: a scoped architecture connecting 8 data zones and 11 heterogeneous source systems; a consumption forecasting prototype using time-series modelling on two years of cleaned meter data; anomaly and fraud detection algorithms; interactive dashboards for three distinct decision-maker profiles; a cybersecurity risk assessment anchored in Néovolt's actual asset inventory; and a full programme governance framework.

Estimated total programme budget over 18 months: €1.2M – €1.6M, with a projected ROI of 220–280% driven primarily by avoided emergency energy purchases, fraud recovery, and reduced incident response costs. The programme is recommended to be phased: data infrastructure and quality first (months 1–6), then predictive models (months 7–12), then full dashboard rollout and security hardening (months 13–18).

This document constitutes the common trunk of the project dossier. It covers: needs analysis and scoping, target architecture, project organisation, and cross-cutting dimensions (ethics, security-by-design, Green IT, data governance, and innovation outlook).

1.Note de cadrage :

1.1 Reformulation du besoin :

Néovolt exploite un réseau de distribution d'électricité et de gaz alimentant environ 600 000 foyers et professionnels sur un territoire mixte. Depuis deux ans, l'entreprise déploie des compteurs communicants : dans notre jeu de données, 640 des 700 compteurs actifs sont de type « communicant », soit 91,4 %, couvrant 8 zones géographiques (Val-Nord, Centre-Ville, Coteaux-Ouest, Plateau-Est, Rives-Sud, Bourg-Ancien, Parc-Tertiaire, Zone-Industrielle).

Ces compteurs génèrent des relevés toutes les 30 minutes — soit potentiellement 17 280 points par compteur et par jour à l'échelle du parc réel. Le jeu de données fourni contient 512 986 relevés journaliers sur deux ans (2024-2025), plus un échantillon de relevés horaires. Ces données sont aujourd'hui sous-exploitées, mal centralisées et de qualité inégale.

La direction générale et la DSI lancent le programme Néovolt Grid+ pour transformer cette masse de données brutes en valeur métier concrète.

1.2 Problèmes identifiés :

Problème	Symptômes observés dans les données	Impact métier
Sous-exploitation des données	Relevés journaliers et horaires non corrélés aux incidents (421 incidents réseau), à la météo ou aux réclamations (4 459 réclamations clients)	Décisions non fondées sur la donnée
Pics mal anticipés	Pas de modèle prédictif ; corrélation météo-consommation non exploitée alors que 2 ans de données météo par zone sont disponibles	Achats spot coûteux, fragilité réseau
Détection tardive des anomalies	25 cas de fraude confirmés détectés tardivement ; anomalies de type « sous-comptage » dominantes	Pertes financières, risque juridique
Absence de tableaux de bord	Données dispersées (11 actifs SI distincts, propriétaires multiples : DSI, Sécurité SI, Relation client, Exploitation réseau)	Pilotage aveugle pour les décideurs
Sécurité non auditée	9 actifs critiques exposés (internet ou DMZ) dont portail client, API, passerelle télérelève ; données personnelles partout	Risque cyber, non-conformité RGPD/NIS2
Absence de pilotage programme	Pas de cadrage budgétaire, pas de gouvernance des données, pas de conduite du changement documentée	Programme sans cap ni responsable

1.3 Périmètre retenu

Dans le cadre de ce sprint de cinq jours, notre équipe se concentre sur les périmètres suivants :

- Données : jeu de données fourni (relevés consommation, compteurs, clients, météo, incidents, fraudes confirmées, réclamations, journaux de sécurité, inventaire des actifs SI).
- Prototypage fonctionnel : pipeline d'ingestion et de nettoyage des données, modèle de prévision de consommation, détection d'anomalies, tableaux de bord décisionnels, analyse de risques cyber.
- Conception : architecture cible complète (non déployée en production), gouvernance des données, plan de projet et business case.

Sont hors périmètre du prototype (mais traités au niveau de la conception) : la mise en production de l'infrastructure complète, l'intégration avec les systèmes legacy de Néovolt, la mise en conformité opérationnelle RGPD.

1.4 Objectifs du programme :

#	Objectif	Indicateur	
O1	Centraliser et qualifier les données des compteurs communicants	Taux complétude données	
O2	Prévoir la consommation à J+1 et J+7 par zone	MAPE prévision	
O3	Détecter les anomalies et fraudes en moins de 7 jours	Délai détection moyen	
O4	Fournir des tableaux de bord décisionnels pour 3 profils métier	Satisfaction utilisateurs pilotes	
O5	Réduire les achats spot d'énergie grâce à la prévision	Coût achats spot	
O6	Atteindre la conformité RGPD et NIS2 sur la plateforme data	Non-conformités critiques ouvertes	

1.5 Hypothèses

- Le jeu de données fourni (700 compteurs, 512 986 relevés) est représentatif du parc réel à l'échelle 1:860 (600 000 points de livraison / 700).
- Le coût unitaire d'un achat spot d'énergie est estimé à 3× le coût de fourniture normal
- La plateforme cible sera hébergée sur un cloud souverain européen pour répondre aux exigences de localisation des données personnelles.
- Les équipes métier Néovolt disposent d'au moins 2 h/semaine pour participer aux ateliers de conduite du changement.

- Un délai de détection de fraude supérieur à 30 jours génère une perte financière moyenne de 1 200 € par compteur fraudé (hypothèse basée sur les 25 cas confirmés).

1.6 Contraintes :

- Réglementaires : RGPD, exigences NIS2 sur les opérateurs d'importance vitale
- Techniques : données imparfaites (manquantes, aberrantes, doublons), SI legacy hétérogène
- Humaines : résistance au changement potentielle des équipes terrain habituées aux fichiers Excel
- Temporelles : prototype en 5 jours, mise en production visée à 12-18 mois.

1.7 Risques principaux :

Risque	Prob.	Impact	Mitigation
Qualité insuffisante des données sources	Élevée	Élevé	Protocole de nettoyage systématique, règles de qualité documentées
Résistance des équipes terrain	Moyenne	Moyen	Plan de conduite du changement, ateliers d'appropriation
Dérive budgétaire	Moyenne	Élevé	Jalons de révision budgétaire trimestriels
Cyberattaque sur la plateforme	Faible	Très élevé	Audit de sécurité, plan de continuité, DevSecOps
Dépendance fournisseur cloud	Moyenne	Moyen	Stratégie multi-cloud ou portabilité contractualisée

2. Vision d'architecture d'ensemble :

L'architecture cible de Néovolt Grid+ s'articule autour de cinq couches fonctionnelles :

SOURCES DE DONNÉES Compteurs communicants · Météo · Incidents réseau · Référentiels clients · Réclamations texte libre
COUCHE DATA ENGINEERING Pipeline d'ingestion (Kafka/batch) · Nettoyage · Stockage (Data Lake + Data Warehouse)
COUCHE ANALYTIQUE & IA Analyse descriptive · Préviction consommation · Détection anomalies/fraudes · NLP réclamations
RESTITUTION DÉCISIONNELLE Tableaux de bord Power BI (exploitation, finance, relation client) · Alertes automatiques
SÉCURITÉ & GOUVERNANCE IAM · Chiffrement · SIEM · Audit · RGPD · RACI · DevSecOps

Cette architecture suit un principe de défense in depth : chaque couche est sécurisée indépendamment, les accès sont cloisonnés par rôle, et toutes les communications entre compteurs et plateforme sont chiffrées.

3.Organisation de projet :

3.1 Composition et rôles de l'équipe :

Membre	Spécialité / Rôle	Périmètre principal dans Néovolt Grid+
Rania MERZOUGUI	Chef de Projet IT	Cadrage stratégique, business case, plan de projet, gouvernance données, conduite du changement, tableau de bord pilotage
Kahina BRAHIMI	Data Analyst	Exploration et nettoyage des données, analyses descriptives, segmentation clients, tableaux de bord décisionnels
Cylia AIRA	Data Scientist	Modèle de prévision consommation, détection d'anomalies et fraudes, évaluation critique, MLOps
Sonia LASKRI	Ingénieur Logiciel & Data Eng.	Pipeline d'ingestion, architecture technique, API exposition, conteneurisation, intégration des volets
Kahina BRAIMI	Cybersécurité	Analyse de risques, audit sécurité prototype, DevSecOps, SIEM/SOC, PCA/PRA, conformité

3.2 Planning du sprint (5 jours) :

Jour	Activités
Lundi 1/06	Kick-off équipe, lecture du dossier de cas, répartition des rôles, note de cadrage v0
Mardi 2/06	Architecture détaillée, mise en place environnements, exploration des données
Mercredi 3/06	Production intensive par volet (pipeline, analyses, modèles, audit sécurité)
Jeudi 4/06	Intégration des contributions, tests, rédaction du dossier, préparation supports
Vendredi 5/06	Finalisation, enregistrement vidéos (démonstration + soutenance), dépôt avant 23h59

4. Dimensions transverses

4.1 Éthique et responsabilité numérique

Les données de consommation constituent des données à caractère personnel au sens du RGPD : elles permettent d'inférer des comportements domestiques (présence au domicile, type d'équipements, habitudes). Nous appliquons les principes suivants :

- Minimisation : seuls les identifiants pseudonymisés (id_pdl, id_client) sont utilisés dans les modèles ; les données nominatives restent dans la base clients (SRV-DB-01), compartimentée.
- Transparence des décisions automatisées : les alertes de fraude générées par le modèle sont systématiquement soumises à validation humaine avant toute action. Un score d'explicabilité (SHAP values) accompagne chaque détection.
- Prévention des biais : le modèle de détection d'anomalies est audité par zone géographique et par profil client (résidentiel / tertiaire / industriel) pour éviter un ciblage injuste de certaines populations. Les 25 cas de fraude confirmés dans le dataset seront utilisés comme ensemble de validation, pas uniquement d'entraînement.
- Droit des personnes : les réclamations clients incluent explicitement des demandes RGPD (ex. REC-00001 : « je m'interroge sur le respect du RGPD »). Une procédure de réponse aux droits d'accès et d'effacement est intégrée au plan de gouvernance.

4.2 Sécurité dès la conception (Security by Design)

L'inventaire des actifs (actifs_si.csv) révèle 9 actifs critiques, dont 3 exposés sur internet ou en DMZ avec des données sensibles (portail client, API espace client, passerelle télérelève).

Nos principes de sécurité by design :

- Chiffrement systématique : TLS 1.3 en transit, AES-256 au repos sur tous les actifs classifiés « critique » ou « élevé ».
- Moindre privilège : accès aux données Or (agrégées) ouvert aux décideurs ; accès aux données Bronze (brutes avec id_client) restreint aux data engineers et à l'audit.
- Authentification forte : MFA obligatoire sur tous les accès à la plateforme data et au SCADA, fédéré via AD-01.
- Journalisation : les journaux de sécurité (journaux_securite.csv) sont ingérés dans le SIEM ; règles de détection d'anomalies d'accès configurées dès le prototype.

4.3 Sobriété numérique et Green IT

- Architecture batch-first : les traitements lourds (Spark) s'exécutent la nuit (2h00-5h00), hors heures de pointe réseau et énergie.
- Rétention limitée : données brutes Bronze conservées 13 mois (obligation réglementaire comptage) ; données Or agrégées conservées 5 ans.
- Dimensionnement à juste mesure : le prototype tourne sur un environnement minimal (1 nœud Docker Compose) ; le dimensionnement production est prévu pour le parc réel (600 000 PDL) mais avec auto-scaling pour éviter le sur-provisionnement.
- Indicateurs Green IT : empreinte carbone des traitements mesurée via CodeCarbon (bibliothèque Python open source) et reportée dans le tableau de bord de pilotage.

4.4 Gouvernance des données

Quatre propriétaires de données coexistent chez Néovolt (DSI, Sécurité SI, Relation client, Exploitation réseau), sans gouvernance formalisée. Notre plan de gouvernance (détaillé dans le Volet A) pose :

- Un catalogue de données couvrant les 11 sources identifiées, avec propriétaire, classification de sensibilité, et politique de rétention.
- Une matrice RACI par dataset (Responsible, Accountable, Consulted, Informed).
- Des règles de qualité automatisées : seuils d'alertes sur les taux de complétude et de valeurs aberrantes, remontés dans le tableau de bord de pilotage.
- Une politique d'accès basée sur les rôles (RBAC) alignée avec l'AD-01 existant.

4.5 Innovation et veille

Nous proposons à Néovolt une ouverture sur deux axes d'innovation pour la suite du programme :

- IA générative pour l'assistance à l'exploitation : un agent LLM (type GPT-4o) connecté aux données Or pourrait expliquer en langage naturel les anomalies détectées (« Le compteur PDL-000151 présente un sous-comptage probable depuis 15 jours, corrélé à une baisse de 34 % de la consommation nocturne sans changement de profil client »). Cela réduirait le temps de diagnostic des exploitants.
- Jumeaux numériques du réseau : à horizon 3 ans, un modèle de simulation du réseau de distribution (digital twin) permettrait de tester des scénarii de charge avant déploiement physique, réduisant les coûts d'intervention et les risques de coupure.

