

Examen de fin de second semestre — Juin 2026

PROJET

NÉOVOLT GRID+

Fait par :

- Rania Chahinez MERZOUGUI
 - Kahina BRAHIMI
 - Cylia AIRA
 - Sonia LASKRI
-

Executive Summary

Néovolt is a regional energy distributor serving approximately 600,000 residential and professional customers across a mixed urban-rural territory. Over the past two years, the company has deployed smart meters (communicating devices) that generate half-hourly readings — amounting to nearly 513,000 daily data points from 700 active metering points in our dataset. Despite this data richness, consumption data remains under-exploited, poorly centralised, and of uneven quality.

The Néovolt Grid+ programme is designed to address four critical business problems:

- Poorly anticipated consumption peaks, leading to costly last-minute energy purchases on spot markets.
- Delayed detection of anomalies and meter fraud — confirmed cases exist (25 validated fraud cases in the dataset) but detection is reactive, sometimes months late.
- Absence of actionable dashboards for network operations, customer relations, and financial management teams.
- An unaudited security posture across smart meters, the data platform, and critical infrastructure, at a time of tightening regulation (GDPR, NIS2, critical infrastructure directives).

Our team has been commissioned by Néovolt's CIO to deliver, in a one-week sprint, a credible prototype and a decision-support dossier covering data engineering, predictive analytics, data visualisation, cybersecurity, and programme management.

Key outputs of this sprint include: a scoped architecture connecting 8 data zones and 11 heterogeneous source systems; a consumption forecasting prototype using time-series modelling on two years of cleaned meter data; anomaly and fraud detection algorithms; interactive dashboards for three distinct decision-maker profiles; a cybersecurity risk assessment anchored in Néovolt's actual asset inventory; and a full programme governance framework.

Estimated total programme budget over 18 months: €1.2M – €1.6M, with a projected ROI of 220–280% driven primarily by avoided emergency energy purchases, fraud recovery, and reduced incident response costs. The programme is recommended to be phased: data infrastructure and quality first (months 1–6), then predictive models (months 7–12), then full dashboard rollout and security hardening (months 13–18).

This document constitutes the common trunk of the project dossier. It covers: needs analysis and scoping, target architecture, project organisation, and cross-cutting dimensions (ethics, security-by-design, Green IT, data governance, and innovation outlook).

1.Note de cadrage :

1.1 Reformulation du besoin :

Néovolt exploite un réseau de distribution d'électricité et de gaz alimentant environ 600 000 foyers et professionnels sur un territoire mixte. Depuis deux ans, l'entreprise déploie des compteurs communicants : dans notre jeu de données, 640 des 700 compteurs actifs sont de type « communicant », soit 91,4 %, couvrant 8 zones géographiques (Val-Nord, Centre-Ville, Coteaux-Ouest, Plateau-Est, Rives-Sud, Bourg-Ancien, Parc-Tertiaire, Zone-Industrielle).

Ces compteurs génèrent des relevés toutes les 30 minutes — soit potentiellement 17 280 points par compteur et par jour à l'échelle du parc réel. Le jeu de données fourni contient 512 986 relevés journaliers sur deux ans (2024-2025), plus un échantillon de relevés horaires. Ces données sont aujourd'hui sous-exploitées, mal centralisées et de qualité inégale.

La direction générale et la DSI lancent le programme Néovolt Grid+ pour transformer cette masse de données brutes en valeur métier concrète.

1.2 Problèmes identifiés :

Problème	Symptômes observés dans les données	Impact métier
Sous-exploitation des données	Relevés journaliers et horaires non corrélés aux incidents (421 incidents réseau), à la météo ou aux réclamations (4 459 réclamations clients)	Décisions non fondées sur la donnée
Pics mal anticipés	Pas de modèle prédictif ; corrélation météo-consommation non exploitée alors que 2 ans de données météo par zone sont disponibles	Achats spot coûteux, fragilité réseau
Détection tardive des anomalies	25 cas de fraude confirmés détectés tardivement ; anomalies de type « sous-comptage » dominantes	Pertes financières, risque juridique
Absence de tableaux de bord	Données dispersées (11 actifs SI distincts, propriétaires multiples : DSI, Sécurité SI, Relation client, Exploitation réseau)	Pilotage aveugle pour les décideurs
Sécurité non auditée	9 actifs critiques exposés (internet ou DMZ) dont portail client, API, passerelle télérelève ; données personnelles partout	Risque cyber, non-conformité RGPD/NIS2
Absence de pilotage programme	Pas de cadrage budgétaire, pas de gouvernance des données, pas de conduite du changement documentée	Programme sans cap ni responsable

1.3 Périmètre retenu

Dans le cadre de ce sprint de cinq jours, notre équipe se concentre sur les périmètres suivants :

- Données : jeu de données fourni (relevés consommation, compteurs, clients, météo, incidents, fraudes confirmées, réclamations, journaux de sécurité, inventaire des actifs SI).
- Prototypage fonctionnel : pipeline d'ingestion et de nettoyage des données, modèle de prévision de consommation, détection d'anomalies, tableaux de bord décisionnels, analyse de risques cyber.
- Conception : architecture cible complète (non déployée en production), gouvernance des données, plan de projet et business case.

Sont hors périmètre du prototype (mais traités au niveau de la conception) : la mise en production de l'infrastructure complète, l'intégration avec les systèmes legacy de Néovolt, la mise en conformité opérationnelle RGPD.

1.4 Objectifs du programme :

#	Objectif	Indicateur	
O1	Centraliser et qualifier les données des compteurs communicants	Taux complétude données	
O2	Prévoir la consommation à J+1 et J+7 par zone	MAPE prévision	
O3	Détecter les anomalies et fraudes en moins de 7 jours	Délai détection moyen	
O4	Fournir des tableaux de bord décisionnels pour 3 profils métier	Satisfaction utilisateurs pilotes	
O5	Réduire les achats spot d'énergie grâce à la prévision	Coût achats spot	
O6	Atteindre la conformité RGPD et NIS2 sur la plateforme data	Non-conformités critiques ouvertes	

1.5 Hypothèses

- Le jeu de données fourni (700 compteurs, 512 986 relevés) est représentatif du parc réel à l'échelle 1:860 (600 000 points de livraison / 700).
- Le coût unitaire d'un achat spot d'énergie est estimé à 3× le coût de fourniture normal
- La plateforme cible sera hébergée sur un cloud souverain européen pour répondre aux exigences de localisation des données personnelles.
- Les équipes métier Néovolt disposent d'au moins 2 h/semaine pour participer aux ateliers de conduite du changement.
- Un délai de détection de fraude supérieur à 30 jours génère une perte financière moyenne de 1 200 € par compteur fraudé (hypothèse basée sur les 25 cas confirmés).

1.6 Contraintes :

- Réglementaires : RGPD, exigences NIS2 sur les opérateurs d'importance vitale
- Techniques : données imparfaites (manquantes, aberrantes, doublons), SI legacy hétérogène
- Humaines : résistance au changement potentielle des équipes terrain habituées aux fichiers Excel
- Temporelles : prototype en 5 jours, mise en production visée à 12-18 mois.

1.7 Risques principaux :

Risque	Prob.	Impact	Mitigation
Qualité insuffisante des données sources	Élevée	Élevé	Protocole de nettoyage systématique, règles de qualité documentées
Résistance des équipes terrain	Moyenne	Moyen	Plan de conduite du changement, ateliers d'appropriation
Dérive budgétaire	Moyenne	Élevé	Jalons de révision budgétaire trimestriels
Cyberattaque sur la plateforme	Faible	Très élevé	Audit de sécurité, plan de continuité, DevSecOps
Dépendance fournisseur cloud	Moyenne	Moyen	Stratégie multi-cloud ou portabilité contractualisée

2. Vision d'architecture d'ensemble :

L'architecture cible de Néovolt Grid+ s'articule autour de cinq couches fonctionnelles :

SOURCES DE DONNÉES Compteurs communicants · Météo · Incidents réseau · Référentiels clients · Réclamations texte libre
COUCHE DATA ENGINEERING Pipeline d'ingestion (Kafka/batch) · Nettoyage · Stockage (Data Lake + Data Warehouse)
COUCHE ANALYTIQUE & IA Analyse descriptive · Préviction consommation · Détection anomalies/fraudes · NLP réclamations
RESTITUTION DÉCISIONNELLE Tableaux de bord Power BI (exploitation, finance, relation client) · Alertes automatiques
SÉCURITÉ & GOUVERNANCE IAM · Chiffrement · SIEM · Audit · RGPD · RACI · DevSecOps

Cette architecture suit un principe de défense in depth : chaque couche est sécurisée indépendamment, les accès sont cloisonnés par rôle, et toutes les communications entre compteurs et plateforme sont chiffrées.

3.Organisation de projet :

3.1 Composition et rôles de l'équipe :

Membre	Spécialité / Rôle	Périmètre principal dans Néovolt Grid+
Rania MERZOUGUI	Chef de Projet IT	Cadrage stratégique, business case, plan de projet, gouvernance données, conduite du changement, tableau de bord pilotage
Kahina BRAHIMI	Data Analyst	Exploration et nettoyage des données, analyses descriptives, segmentation clients, tableaux de bord décisionnels
Cylia AIRA	Data Scientist	Modèle de prévision consommation, détection d'anomalies et fraudes, évaluation critique, MLOps
Sonia LASKRI	Ingénieur Logiciel & Data Eng.	Pipeline d'ingestion, architecture technique, API exposition, conteneurisation, intégration des volets
Kahina BRAIMI	Cybersécurité	Analyse de risques, audit sécurité prototype, DevSecOps, SIEM/SOC, PCA/PRA, conformité

3.2 Planning du sprint (5 jours) :

Jour	Activités
Lundi 1/06	Kick-off équipe, lecture du dossier de cas, répartition des rôles, note de cadrage v0
Mardi 2/06	Architecture détaillée, mise en place environnements, exploration des données
Mercredi 3/06	Production intensive par volet (pipeline, analyses, modèles, audit sécurité)
Jeudi 4/06	Intégration des contributions, tests, rédaction du dossier, préparation supports
Vendredi 5/06	Finalisation, enregistrement vidéos (démonstration + soutenance), dépôt avant 23h59

4. Dimensions transverses

4.1 Éthique et responsabilité numérique

Les données de consommation constituent des données à caractère personnel au sens du RGPD : elles permettent d'inférer des comportements domestiques (présence au domicile, type d'équipements, habitudes). Nous appliquons les principes suivants :

- Minimisation : seuls les identifiants pseudonymisés (id_pdl, id_client) sont utilisés dans les modèles ; les données nominatives restent dans la base clients (SRV-DB-01), compartimentée.
- Transparence des décisions automatisées : les alertes de fraude générées par le modèle sont systématiquement soumises à validation humaine avant toute action. Un score d'explicabilité (SHAP values) accompagne chaque détection.
- Prévention des biais : le modèle de détection d'anomalies est audité par zone géographique et par profil client (résidentiel / tertiaire / industriel) pour éviter un ciblage injuste de certaines populations. Les 25 cas de fraude confirmés dans le dataset seront utilisés comme ensemble de validation, pas uniquement d'entraînement.
- Droit des personnes : les réclamations clients incluent explicitement des demandes RGPD (ex. REC-00001 : « je m'interroge sur le respect du RGPD »). Une procédure de réponse aux droits d'accès et d'effacement est intégrée au plan de gouvernance.

4.2 Sécurité dès la conception (Security by Design)

L'inventaire des actifs (actifs_si.csv) révèle 9 actifs critiques, dont 3 exposés sur internet ou en DMZ avec des données sensibles (portail client, API espace client, passerelle télérelève). Nos principes de sécurité by design :

- Chiffrement systématique : TLS 1.3 en transit, AES-256 au repos sur tous les actifs classifiés « critique » ou « élevé ».
- Moindre privilège : accès aux données Or (agrégées) ouvert aux décideurs ; accès aux données Bronze (brutes avec id_client) restreint aux data engineers et à l'audit.
- Authentification forte : MFA obligatoire sur tous les accès à la plateforme data et au SCADA, fédéré via AD-01.
- Journalisation : les journaux de sécurité (journaux_securite.csv) sont ingérés dans le SIEM ; règles de détection d'anomalies d'accès configurées dès le prototype.

4.3 Sobriété numérique et Green IT

- Architecture batch-first : les traitements lourds (Spark) s'exécutent la nuit (2h00-5h00), hors heures de pointe réseau et énergie.

- Rétention limitée : données brutes Bronze conservées 13 mois (obligation réglementaire comptage) ; données Or agrégées conservées 5 ans.
- Dimensionnement à juste mesure : le prototype tourne sur un environnement minimal (1 nœud Docker Compose) ; le dimensionnement production est prévu pour le parc réel (600 000 PDL) mais avec auto-scaling pour éviter le sur-provisionnement.
- Indicateurs Green IT : empreinte carbone des traitements mesurée via CodeCarbon (librairie Python open source) et reportée dans le tableau de bord de pilotage.

4.4 Gouvernance des données

Quatre propriétaires de données coexistent chez Néovolt (DSI, Sécurité SI, Relation client, Exploitation réseau), sans gouvernance formalisée. Notre plan de gouvernance (détaillé dans le Volet A) pose :

- Un catalogue de données couvrant les 11 sources identifiées, avec propriétaire, classification de sensibilité, et politique de rétention.
- Une matrice RACI par dataset (Responsible, Accountable, Consulted, Informed).
- Des règles de qualité automatisées : seuils d'alertes sur les taux de complétude et de valeurs aberrantes, remontés dans le tableau de bord de pilotage.
- Une politique d'accès basée sur les rôles (RBAC) alignée avec l'AD-01 existant.

4.5 Innovation et veille

Nous proposons à Néovolt une ouverture sur deux axes d'innovation pour la suite du programme :

- IA générative pour l'assistance à l'exploitation : un agent LLM (type GPT-4o) connecté aux données Or pourrait expliquer en langage naturel les anomalies détectées (« Le compteur PDL-000151 présente un sous-comptage probable depuis 15 jours, corrélé à une baisse de 34 % de la consommation nocturne sans changement de profil client »). Cela réduirait le temps de diagnostic des exploitants.
- Jumeaux numériques du réseau : à horizon 3 ans, un modèle de simulation du réseau de distribution (digital twin) permettrait de tester des scénarii de charge avant déploiement physique, réduisant les coûts d'intervention et les risques de coupure.

Volet A — Chef de Projet IT et Data

Dans le cadre du projet transverse Néovolt Grid+, la prise en charge du Volet A, correspondant à la spécialité Chef de Projet IT et Data, a consisté à définir le cadrage du programme, à en établir le chiffrage et à garantir sa cohérence globale. Ce rôle a été essentiel pour assurer l'alignement des différents livrables produits par les autres membres de l'équipe (pipeline de données, modèles de machine learning, tableaux de bord et audit cybersécurité) avec les besoins réels de Néovolt, en évitant toute divergence dans les orientations retenues.

Ce volet s'articule autour de cinq livrables principaux : la note de cadrage stratégique accompagnée du business case, le plan de projet, la gouvernance des données, le plan de conduite du changement et le tableau de bord de pilotage. Les travaux réalisés se sont appuyés sur les données réelles fournies dans le dossier de cas afin de garantir la pertinence et la crédibilité des estimations présentées. Lorsque certaines données étaient indisponibles, des hypothèses ont été formulées et explicitement identifiées comme telles.

1. Note de cadrage stratégique et Business Case

1.1 Enjeux stratégiques pour Néovolt

Avant de construire un business case, il faut comprendre pourquoi Néovolt a un problème urgent. En analysant les données fournies, j'ai identifié trois signaux d'alarme concrets :

- **Signal 1 La satisfaction client est en chute libre**

Sur 3 000 réclamations clients analysées, la satisfaction moyenne n'est que de 2,45/5. C'est très bas pour un prestataire de service essentiel. Les réclamations arrivent par quatre canaux équilibrés (email, espace client, courrier, téléphone), ce qui montre que les clients cherchent à se faire entendre par tous les moyens. Parmi les réclamations, on trouve des inquiétudes explicites sur le RGPD. Si Néovolt ne réagit pas, le risque réputationnel et réglementaire est réel.

- **Signal 2 Les fraudes ne sont détectées que tardivement**

Le dataset contient 24 cas de fraude confirmés (14 sous-comptages, 6 branchements illicites, 4 compteurs trafiqués). À l'échelle réelle du parc (600 000 PDL), cela représente potentiellement plus de 20 000 cas si le taux est similaire. Chaque cas non détecté représente une perte financière directe. En se basant sur une hypothèse de perte moyenne de 1 200 €/an par compteur fraudé et un délai de détection actuel d'environ 3 à 6 mois, les pertes annuelles estimées dépassent 24 M€ à l'échelle réelle.

- **Signal 3 Le réseau subit des incidents coûteux et mal anticipés**

Sur la période analysée, 420 incidents réseau ont été enregistrés avec une durée moyenne de 98 minutes. La Zone Industrielle concentre les consommations les plus élevées (moy. 368 kWh par relevé), ce qui en fait la zone la plus critique en cas de pic. Sans prévision de consommation, Néovolt achète de l'énergie en urgence sur le marché spot — à un coût estimé 2 à 3 fois supérieur au prix normal.

1.2 Objectifs mesurables du programme

Obj.	Intitulé	Indicateur	Cible M18
O1	Centraliser et qualifier les données de comptage	Taux de complétude des relevés	> 95 %
O2	Prévoir la consommation à J+1 et J+7 par zone	MAPE du modèle de prévision	< 8 %
O3	Détecter les fraudes en moins de 7 jours	Délai moyen de détection	< 7 jours
O4	Fournir des tableaux de bord à 3 profils métier	Adoption utilisateurs pilotes	> 80 % à M12
O5	Réduire les achats spot d'énergie d'urgence	Coût des achats spot	- 20 % à M12
O6	Atteindre la conformité RGPD et NIS2	Non-conformités critiques ouvertes	0 à M18

1.3 Business Case — Analyse coûts-bénéfices

Le business case a été construit en trois étapes : l'estimation des coûts du programme, l'évaluation des gains attendus, puis le calcul du retour sur investissement (ROI). L'ensemble des hypothèses retenues est explicitement présenté.

Coûts du programme (sur 18 mois)

Poste de coût	Hypothèse [H]	Coût estimé	Commentaire
Infrastructure cloud	3 serveurs + stockage objet	72 000 €	4 000 €/mois × 18 mois
Licences logicielles (Power BI)	5 licences utilisateurs	9 000 €	100 €/mois × 5 × 18
Développement et intégration (équipe interne)	2 ETP data engineer 12 mois	120 000 €	5 000 €/mois × 2 × 12
Data scientist (modèles ML)	1 ETP 8 mois	44 000 €	5 500 €/mois × 8
Chef de projet IT	1 ETP 18 mois	108 000 €	6 000 €/mois × 18
Cybersécurité et conformité	Prestation + 1 ETP 6 mois	65 000 €	Audit + durcissement
Formation et conduite du changement	3 équipes × 2 jours	18 000 €	Formation + ateliers
Imprévus et dépassements (10 %)	Provision standard	43 600 €	Recommandé en gestion projet
TOTAL DES COÛTS		479 600 €	≈ 480 000 €

Gains attendus (annuels, à partir de M12)

Source de gain	Hypothèse [H]	Gain annuel estimé	Confiance
Réduction achats spot énergie (prévision J+7)	Achats spot actuels : 2 M€/an [H], réduction de 20 %	400 000 €	Moyenne
Récupération fraudes détectées rapidement	20 000 cas × 1 200 €/an × taux détection 30 % [H]	7 200 000 €	Hypothétique
Réduction coûts d'intervention réseau	420 incidents × 98 min × 80 €/h [H], gain 15 %	82 320 €	Bonne
Évitement d'amendes RGPD	Risque amende : 2 % CA [H], proba 10 % sans projet	150 000 €	Faible
Productivité équipes (moins d'Excel, alertes auto)	5 agents × 2h/sem économisées × 50 semaines × 35 €/h [H]	17 500 €	Bonne
TOTAL GAINS ANNUELS	(fraudes = fourchette haute)	≈ 7 850 000 €	
TOTAL GAINS (hors fraudes, prudent)	Scénario conservateur	≈ 650 000 €	

Calcul du ROI

Indicateur	Scénario conservateur	Scénario optimiste	Avec fraudes
Coût total programme	480 000 €	480 000 €	480 000 €
Gains annuels (à partir M12)	650 000 €	900 000 €	7 850 000 €
Retour sur investissement (ROI)	+ 35 %	+ 88 %	+ 1 535 %
Point de retour	M22 environ	M18 environ	M10 environ

2. Plan de projet et de portefeuille

2.1 Découpage en lots et jalons

Le programme a été déoupé en trois phases sur 18 mois. L'ordre a été choisi par valeur et par dépendance technique : on ne peut pas construire des modèles ML sans des données propres, et on ne peut pas déployer des dashboards sans API. La cybersécurité court sur toute la durée.

Phase	Période	Lots	Jalons clés	Budget
Phase 1 : Fondations	M1 – M6	L1 : Pipeline ingestion et nettoyage données L2 : Architecture data lake (Bronze/Argent/Or) L3 : Audit sécurité et premières corrections	M3 : Pipeline opérationnel M6 : Data lake Bronze-Or opérationnel M6 : Rapport audit cyber livré	195 000 €
Phase 2 : Intelligence	M7 – M12	L4 : Modèles prévision et détection anomalies L5 : API exposition des résultats L6 : Tableaux de bord v1 (3 profils)	M9 : Modèle prévision en prod M11 : Détection fraudes active M12 : Dashboards livrés aux pilotes	185 000 €
Phase 3 : Déploiement	M13 – M18	L7 : Généralisation des dashboards L8 : DevSecOps et conformité RGPD/NIS2 L9 : Formation et passage en run	M15 : Conformité RGPD validée M17 : Formation équipes terminée M18 : Passage en exploitation	100 000 €

2 Dépendances entre lots

- L1 → L4 : Le pipeline d'ingestion (L1) doit fonctionner avant de pouvoir entraîner des modèles (L4).
- L2 → L5 : Le data lake structuré (L2) est le socle des API (L5) qui alimentent les dashboards.
- L3 → L8 : L'audit (L3) identifie les failles à corriger dans la phase de déploiement (L8).
- L4 + L5 → L6 : Les modèles (L4) et les API (L5) doivent être disponibles pour construire les dashboards (L6).
- L6 → L7 : La généralisation (L7) s'appuie sur les retours des utilisateurs pilotes (L6).

2.3 Gestion des risques projet

Risque	Prob.	Impact	Score	Plan d'action
Données de mauvaise qualité → modèles inutilisables	Élevée	Élevé	Critique	Pipeline de validation automatique dès M1 ; seuil qualité défini avant entraînement des modèles
Résistance des équipes terrain aux nouveaux outils	Élevée	Moyen	Fort	Plan de conduite du changement (Section 4) ; implication dès la Phase 1 dans les ateliers de co-construction
Dépassement budgétaire sur l'infrastructure cloud	Moyenne	Moyen	Moyen	Revue budgétaire mensuelle ; alertes de coût cloud configurées ; clause de révision à M6
Cyberattaque sur la plateforme pendant le déploiement	Faible	Critique	Fort	Tests d'intrusion sur le prototype avant M6 ; segmentation réseau dès Phase 1

Biais du modèle de fraude → contestation juridique	Moyenne	Élevé	Fort	Audit d'équité systématique ; validation humaine obligatoire avant toute action sur un client
Turnover d'un profil clé en cours de projet	Faible	Élevé	Moyen	Documentation continue (README, ADR) ; binômage sur les postes critiques

3. Plan de gouvernance des données

3.1 Contexte et problème

L'analyse de l'inventaire des actifs fourni (actifs_si.csv) révèle un problème structurel : les 11 actifs critiques du SI de Néovolt ont quatre propriétaires différents (DSI, Sécurité SI, Relation client, Exploitation réseau), sans politique formalisée. Concrètement, cela signifie que personne ne sait exactement qui a le droit de voir quoi, ni qui est responsable quand une donnée est mauvaise ou fuite.

Je propose de structurer la gouvernance autour de trois axes : propriété des données, qualité, et accès.

3.2 Catalogue des données et propriétaires

Dataset	Propriétaire métier	Sensibilité	Rétention	Notes
Relevés consommation	Exploitation réseau	Haute	13 mois brut 5 ans agrégé	Obligation réglementaire de 13 mois. Pseudonymisation obligatoire en Bronze.
Données clients	Relation client	Haute	5 ans après fin contrat	Données personnelles RGPD. Accès restreint. Droit d'accès et d'effacement à gérer.
Données compteurs	Exploitation réseau	Moyenne	Durée de vie actif	Pas de données nominatives directes mais liées aux clients.
Incidents réseau	Exploitation réseau	Faible	3 ans	Données opérationnelles. Utiles pour l'analyse prédictive.
Données météo	DSI	Nulle	Indéfinie	Données externes publiques. Pas de contrainte.
Réclamations clients	Relation client	Haute	3 ans	Contenu textuel libre potentiellement nominatif. Anonymisation recommandée pour l'analyse.
Journaux de sécurité	Sécurité SI	Haute	1 an min (NIS2)	Accès restreint au RSSI et à l'équipe SOC. Non exposés dans les dashboards décideurs.
Fraudes confirmées	DSI + Juridique	Haute	5 ans (procédures)	Données sensibles. Accès limité au responsable fraude et à la direction.

3.3 Matrice RACI — Gouvernance des données

La matrice RACI définit pour chaque processus clé : qui est Responsable (fait le travail), Accountable (rend des comptes), Consulted (consulté), Informed (informé).

Processus	Chef de projet	Data engineer	Exploit. réseau	Relation client	RSSI / Sécu SI
Définir la politique qualité des données	A	R	C	C	I
Ingestion et nettoyage des relevés	I	R / A	C	I	C
Entraînement des modèles ML	C	C	I	I	I
Accès aux données clients (RGPD)	C	I	I	A / R	C
Gestion des droits d'accès (IAM)	C	I	I	I	R / A
Publication des tableaux de bord	A	R	C	C	I
Réponse aux droits RGPD (accès, effacement)	C	I	I	R / A	C
Surveillance SIEM et gestion des incidents	I	I	C	I	R / A

Légende : R = Responsable (fait) · A = Accountable (responsable) · C = Consulted · I = Informed

3.4 Politique de qualité des données

À partir de l'exploration du dataset, les règles identifiées de qualité minimales à implémenter dans le pipeline :

- Complétude : taux de valeurs manquantes sur consommation_kwh inférieur à 5 % par compteur et par mois. Au-delà, une alerte est remontée au Data Engineer responsable.
- Cohérence temporelle : vérification de l'absence de doublons sur le couple (id_pdl, date). Les relevés horaires doivent couvrir 24 créneaux par jour sans interruption.
- Plausibilité : valeurs de consommation négatives ou supérieures à 3 fois la moyenne de la zone sur 30 jours → marquées comme aberrantes et soumises à validation humaine avant traitement.
- Conformité : aucune donnée nominative (nom, adresse) ne doit être présente dans les tables Bronze accessibles aux data scientists.

Ces règles seront implémentées sous forme de tests dbt (suite de tests automatiques dans le pipeline de transformation) et remontées dans un rapport qualité quotidien visible dans le tableau de bord de pilotage.

4. Plan de conduite du changement

4.1 Analyse des parties prenantes

Avant de définir des actions, les parties prenantes et leur rapport probable au projet. C'est une étape que j'estime sous-estimée dans beaucoup de projets IT : on livre une belle solution technique et personne ne l'utilise.

Partie prenante	Impact du projet	Position initiale	Position cible	Enjeu principal
Direction générale / DSI	Faible / Décideur	Sponsor	Champion	ROI, conformité réglementaire, image
Exploitants réseau	Fort (daily use)	Neutre / méfiant	Utilisateur actif	Crainte de perdre leur expertise, complexité perçue des outils
Service client	Fort (alertes fraude)	Neutre	Ambassadeur	Satisfaction moy. 2,45/5 → fort intérêt pour des données client améliorées
Direction financière	Moyen (ROI)	Sceptique	Convaincu	Besoin de chiffres tangibles et fiables, pas de promesses vagues
RSSI / Équipe sécu	Fort (audit)	Vigilant	Partenaire	Risque d'augmentation de la surface d'attaque avec la plateforme data
Clients finaux (600 000 foyers)	Faible (indirect)	Insatisfaits	Satisfaits	Satisfaction 2,45/5, inquiétudes RGPD → amélioration du service visible

4.2 Freins anticipés et leviers

Frein identifié	Pourquoi c'est un vrai risque	Levier proposé
« On faisait ça très bien avec Excel »	Les exploitants réseau ont des habitudes de travail ancrées depuis des années. Un dashboard qui ne répond pas exactement à leur workflow sera abandonné.	Co-construction : les impliquer dans la définition des vues du dashboard dès M2. Partir de leurs fichiers Excel existants pour reproduire leurs indicateurs clés.
Peur de la surveillance (modèle détection fraude)	Si les équipes pensent que la solution sert à surveiller leur travail plutôt qu'à les aider, elles n'alimenteront pas correctement les données.	Communication transparente sur l'objectif (fraude client, pas contrôle interne). Validation humaine systématique des alertes, communiquée clairement.
Surcharge de travail pendant le déploiement	Les équipes opérationnelles ont un travail quotidien. Le projet s'y ajoute sans réduction de charge.	Planifier les formations hors périodes de pointe. Former des référents internes (super-utilisateurs) qui démultiplient la formation.
Manque de confiance dans les données	Si les premières alertes du modèle sont fausses, les	Phase pilote sur 2 zones avant généralisation. Critères de

	utilisateurs décrocheront définitivement.	déploiement définis à l'avance : taux de faux positifs < 15 %.
--	---	---

4.3 Plan d'actions conduite du changement

#	Action	Cible	Période	Succès si...
1	Atelier de cadrage participatif : définir ensemble les KPIs des dashboards	Exploitants réseau + Service client	M1 – M2	Les utilisateurs reconnaissent leurs indicateurs dans le dashboard
2	Communication interne sur les objectifs du projet (quoi, pourquoi, pour qui)	Tous les collaborateurs concernés	M1	80 % des collaborateurs informés avant M2
3	Identification et formation des super-utilisateurs (1 par équipe)	Exploitants réseau, service client, direction financière	M8 – M10	3 super-utilisateurs opérationnels avant phase pilote
4	Phase pilote sur 2 zones (Val-Nord et Zone Industrielle)	Exploitants des zones pilotes	M10 – M12	Taux d'adoption > 70 % sur les zones pilotes
5	Sessions de formation par profil (3 groupes distincts)	Exploitants, Service client, Direction	M13 – M15	Satisfaction formation > 4/5
6	Bilan et ajustements post-déploiement (enquête satisfaction)	Tous utilisateurs	M17 – M18	NPS utilisateurs > 30

5. Tableau de bord de pilotage projet

5.1 Principes de conception

Le tableau de bord de pilotage est destiné au comité de pilotage de Néovolt (DSI, direction générale, responsables métier). Il doit être lisible par un non-technique en moins de 2 minutes. trois axes : avancement du projet, santé des données, valeur métier déjà produite.

5.2 Indicateurs de suivi

#	Indicateur	Définition	Fréquence	Responsable
P1	Avancement du sprint / des lots	% de tâches « Terminé » dans le Kanban	Hebdomadaire	Chef de projet
P2	Consommation budgétaire	Dépenses engagées / budget alloué par phase	Mensuelle	Chef de projet
D1	Taux de complétude des relevés	% de relevés sans valeur manquante sur 30 jours glissants	Quotidienne	Data engineer
D2	Taux de valeurs aberrantes	% de relevés marqués comme aberrants et en attente de validation	Quotidienne	Data analyst
M1	MAPE du modèle de prévision	Erreur absolue moyenne en % sur l'ensemble de test	Après chaque entraînement	Data scientist
M2	Taux de faux positifs (fraude)	% d'alertes fraude invalidées après vérification humaine	Mensuelle	Data scientist
V1	Adoption des tableaux de bord	% d'utilisateurs cibles qui se connectent au moins 1×/semaine	Mensuelle	Chef de projet
V2	Réduction des achats spot	Montant achats spot du mois vs. moyenne M-12	Mensuelle	Dir. financière
S1	Non-conformités critiques ouvertes (RGPD/NIS2)	Nombre de non-conformités critiques sans plan de remédiation actif	Mensuelle	RSSI

Légende : P = Pilotage projet · D = Qualité données · M = Modèles ML · V = Valeur métier · S = Sécurité/conformité

5.3 Cadence de pilotage

Instance	Fréquence	Participants	Ordre du jour type
Stand-up équipe projet	Quotidien (15 min)	Toute l'équipe projet	Avancement du jour, blocages, synchronisation inter-volets
Revue de sprint hebdomadaire	Hebdomadaire	Équipe projet + DSI	Revue Kanban, risques, décisions techniques
Comité de pilotage	Mensuel	DSI, DG, responsables métier, chef de projet	Dashboard pilotage, go/no-go phases, arbitrages budget
Revue budgétaire	Mensuelle	Chef de projet + Direction financière	Consommation vs budget, risques de dépassement