

NÉOVOLT GRID+

AIRA Cylia
BRAHIMI Kahina
LASKRI Sonia
MERZOUGUI Rania chahinez



Sommaire



1

Contexte et problématique

2

Partie 3

3

Volet A

4

Volet B

6

Volet C

7

Volet D

8

Volet E

Conclusion

Contexte Néovolt

600 000

clients

700

compteurs actifs

513 000

relevés / jour

8

zones géographiques

5 problèmes identifiés

Pics mal anticipés

Achats d'énergie en urgence (coût ×3)

Fraudes non détectées

25 cas confirmés, délai > 3–6 mois

Absence de dashboards

11 systèmes SI sans pilotage unifié

Sécurité non auditée


9 actifs critiques exposés (NIS2/RGPD)

Satisfaction client

Moyenne 2,45/5 sur 3 000 réclamations

Architecture & Objectifs

Architecture en 5 couches



6 objectifs mesurables (à M18)

O1	Complétude données > 95 %
O2	MAPE prévision J+7 < 8 %
O3	Délai détection fraude < 7 jours
O4	Adoption dashboards > 80 %
O5	Réduction achats spot – 20 %
O6	Conformité RGPD/NIS2 0 écarts

Plan de projet & Business Case

Planning en 3 phases — 18 mois



BUDGET TOTAL : 480 000 €

Retour sur investissement



Gouvernance & Risques

4 dimensions transverses garantissant la réussite du programme

Gouvernance

Catalogue données · RACI · RBAC · Qualité automatisée dbt

Sécurité

TLS 1.3 · AES-256 · MFA · SIEM · DevSecOps

Green IT

Batch nocturne · Rétention limitée · CodeCarbon

Conduite du changement

6 actions clés · Super-utilisateurs · Phase pilote 2 zones

En résumé

Néovolt Grid+ transforme 513 000 relevés journaliers en valeur concrète : réduction des coûts spot, détection rapide des fraudes et pilotage en temps réel. Budget : 480 000 € · ROI estimé : +35 % à +1 535 % · Horizon : 18 mois.

1

2

3

4

5

6

7

8

Volet B: Data Analyste

Contexte et données

- L'objectif de ce volet était d'analyser des données liées à la consommation énergétique afin d'identifier des tendances, des comportements clients et proposer des recommandations métier.
- On a travaillé sur plusieurs tables:

table	nb_lignes	valeurs_manquantes
actifs_si.csv	28	0
cas_fraude_confirmer.csv	24	0
clients.csv	700	274
compteurs.csv	700	0
incidents_reseau.csv	420	0
journaux_securite.csv	47824	0
meteo.csv	5848	0
reclamations.csv	3000	0
releves_consommation.csv	512986	6856
releves_horaires_echantillon.csv	21600	0

Préparation de données

Avant l'analyse, un travail de nettoyage a été réalisé :

Suppression des doublons

Correction des formats de dates

Gestion des valeurs manquantes

Détection et filtrage des valeurs aberrantes

1

2

3

4

5


6

7


8

Dashboards


Consommation Par Zone




Consommation par mois




Consommation par type de compteur



Top 10 consommateurs



Consommation par type de client





Volet C : Data Scientist

1

2

3

4

5

6

7

8

Cette partie du projet est consacrée à l'approche Data Science.

L'objectif était de concevoir et d'évaluer deux modèles prédictifs :

un modèle de prévision de la consommation énergétique et **un**

modèle de détection de fraude, basé sur l'analyse des données.

1

2

3

4

5

6

7

8

Modèle de prediction de la consommation énergétique



Objectif : prédire la consommation énergétique et mettre à disposition via une architecture logicielle

Architecture globale de la solution



1

2

3

4

5

6

7

8

Sources de données
(relevés_consommation. + Météo)



Collecte



Pipeline de préparation

- nettoyage
- transformation
- feature engineering



Modélisation
(Gradient Boosting)



Prédictions
(Consommation énergétique)



Exploitation métier
(Dashboard, aide à la décision)



1

2

3

4

5

6

7

8

- **Données utilisées**

- `relevés_consommation.csv(date, consommation_kwh)`
- `meteo.csv(date, temp_moyenne_c, temp_min_c, temp_max_c )`

- **Nettoyage des données**

- Suppression des doublons
- Supprimer les valeurs négatives
- Gérer les valeurs manquantes
- Suppression des lignes incomplètes : enlever lignes avec données manquantes

- **Préparation des données**

Je fusionne les données: consommation + météo, parce que la météo influence directement la consommation

`df = pd.merge(df_daily, df_meteo_daily, on="date", how="left")`



• Création des variables Features

afin d'améliorer la capacité du modèle à prédire la consommation énergétique, plusieurs variables explicatives ont été créées

- Variables temporelles : jour_semaine, mois

Explication : La consommation n'est pas la même selon le jour ou la période de l'année.

- Variable "weekend" :

Explication : Le comportement énergétique est différent le week-end

- Variables de décalage (lags) : j'utilise la consommation des jours précédents pour prédire la consommation future.

lag_1 = consommation de la veille

lag_7 = consommation du même jour la semaine précédente

1

2

3

4

5

6

7

8

- **Création des variables**

- Variables Température

Explication : La météo influence directement la consommation : froid → chauffage → consommation augmente

- **Modélisation Machine Learning**

Trois modèles ont été testés afin d'évaluer leur capacité à prédire la consommation énergétique quotidienne

- Linear Regression
- Random Forest
- Gradient Boosting

- **Évaluation des modèles**

Plusieurs métriques sont utilisées pour évaluer les performances du modèle

- MAE → erreur moyenne
- RMSE → erreur plus sévère
- R^2 → qualité globale

1

2

3

4

5

6

7

8

- **Modèle retenu : Gradient Boosting**

Les trois modèles présentent de bonnes performances avec un coefficient de détermination supérieur à 0,88. Le modèle Gradient Boosting obtient les meilleurs résultats avec un MAE de 2515 kWh, un RMSE de 4151 kWh et un R^2 de 0,895. Il a donc été retenu comme modèle principal pour la prévision de consommation.

	Modèle	MAE	RMSE	R^2
0	LinearRegression	2546.006570	4378.478356	0.883195
1	RandomForest	2638.445036	4261.383124	0.889359
2	GradientBoosting	2514.809504	4151.452778	0.894994

- Le modèle est sauvegardé dans un fichier afin de pouvoir être réutilisé sans nécessiter un nouvel entraînement. Cette étape est essentielle pour le déploiement du modèle en production. **`joblib.dump(best_model, "models/gradient_boosting_v1.pkl")`**

1

2

3

4

5

6

7

8

Modèle de détection de fraude

Les fraudes à la consommation électrique représentent une perte importante pour les fournisseurs d'énergie.



Objectif : détecter automatiquement les comportements suspects.

La demarche suivie

Prétraitement des données

- Conversion des dates.
- Suppression des doublons.
- Traitement des valeurs manquantes.
- Filtrage des consommations négatives.
- Fusion des différentes sources de données.

Feature Engineerin

Création de variables métiers : Conso J-1 (lag temporel), Moyenne glissante 7 jours, Consommation par m², Variables temporelles (jour, mois, weekend)

Déséquilibre des classes

- Forte majorité de non-fraude.
- Technique utilisée : **Undersampling** de la classe majoritaire.
- **Objectif** : équilibrer les classes pour améliorer l'apprentissage.

La demarche suivie

1

2

3

4

5

6

7

8

Modèles testés

- Régression Logistique.
- Random Forest.
- Gradient Boosting.

Évaluation des modèles

- Precision.
- Recall.
- F1-score.
- ROC-AUC.

Resultats

```
[[2125 1379]
 [1833 1670]]
precision    recall  f1-score   support

           0       0.54       0.61       0.57        3504
           1       0.55       0.48       0.51        3503

 accuracy          0.54
 macro avg          0.54
weighted avg          0.54

AUC: 0.5574634657573352
```

```
Random Forest
[[3132  372]
 [ 269 3234]]
precision    recall  f1-score   support

           0       0.92       0.89       0.91        3504
           1       0.90       0.92       0.91        3503

 accuracy          0.91
 macro avg          0.91
weighted avg          0.91

AUC: 0.9747324781628792
```

```
Gradient Boosting
[[3208  296]
 [  37 3466]]
precision    recall  f1-score   support

           0       0.99       0.92       0.95        3504
           1       0.92       0.99       0.95        3503

 accuracy          0.95
 macro avg          0.95
weighted avg          0.95

AUC: 0.9890568358236971
```



Meilleur Model est : **Gradient Boosting**



1

2

3

4

5

6

7

8

Volet D : Ingénierie Logiciel et Data Engineering

Ce volet constitue la fondation technique du projet.
Il vise à transformer les modèles de data science en une solution complète, scalable et exploitable en production.

La demarche suivie

Architecture de la plateforme Néovolt

- **Ingestion des données** : collecte des relevés de compteurs depuis différentes sources.
- **Preprocessing** : Nettoyage, transformation et création de variables pour le modèle.
- **Modèle de détection de fraude** : Algorithme de machine learning entraîné pour identifier les comportements suspects.
- **Fichier main**: orchestrer l'ensemble de pipeline.
- **Exposition via API REST (FastAPI)** : Exposition du modèle sous forme de service accessible par requêtes HTTP.
- **Interface utilisateur (Streamlit)** : Application permettant la visualisation et l'interaction avec le modèle

```
fast.py  
ingestion.py  
Interface.py  
main.py  
preprocessing.py  
training.py
```

La démarche suivie

API et exposition des services

Mise à disposition du modèle

- API développée avec FastAPI
- Endpoint /predict
- Retour :
 - prédiction (fraude / non fraude)
 - probabilité associée

default

GET

/ Home

POST

/predict Predict

Parameters

No parameters

Request body **required**

Example Value | Schema

```
{
  "consommation_kwh": 0,
  "conso_j_1": 0,
  "moyenne_7j": 0,
  "std_7j": 0,
  "variation_pct": 0,
  "conso_par_m2": 0,
  "jour_semaine": 0,
  "mois": 0,
  "weekend": 0,
  "surface_m2": 0,
  "nb_personnes_foyer": 0,
  "puissance_souscrite_kva": 0
}
```

Responses

La demarche suivie

Application Streamlit

- Interface interactive pour l'utilisateur.
- Saisie des caractéristiques client.
- Affichage du niveau de risque.
- Visualisation de la probabilité de fraude.

Neovolt - Détection de Fraude Électrique

Analyse intelligente des consommations pour détecter les comportements suspects.

Données du client

Consommation (kWh)

120,00

- +

Jour de semaine

0

▼

Conso J-1

110,00

- +

Mois

1

▼

Moyenne 7 jours

100,00

- +

Weekend

0

▼

Écart-type 7 jours

15,00

- +

Surface (m²)

50,00

- +

Variation (%)

0,18

- +

Nombre de personnes

3

- +

Conso / m²

2,50

- +

Puissance (kVA)

6,00

- +

 Analyser le risque

Résultat de l'analyse

Probabilité fraude

15.32%

 CLIENT NORMAL

 Analyse

Comportement normal

Déploiement

Mise en production :

- Déploiement sur Render.
- Deux services indépendants :
 - API FastAPI :
<https://projet-neovolt-5.onrender.com>
 - Frontend Streamlit :
<https://projet-neovolt-3.onrender.com>

Start Command

Render runs this command to start your app with each deploy.

```
$ uvicorn fast:app --host 0.0.0.0 --port $PORT
```

 Edit

Start Command

Render runs this command to start your app with each deploy.

```
$ streamlit run Interface.py --server.port 10000 --server.address...
```

 Edit

June 4, 2026 at 1:42 AM ✓ Live

[234fc40](#) interface modifications

All logs ▾

🔍 Search

🕒

Jun 4

```
01:45:25 AM [x59gj] ==> Running 'uvicorn fast:app --host 0.0.0.0 --port $PORT'
01:45:41 AM ==> No open ports detected, continuing to scan...
01:45:41 AM ==> Docs on specifying a port: https://render.com/docs/web-services#port-binding
01:46:06 AM [x59gj] INFO: Started server process [58]
01:46:06 AM [x59gj] INFO: Waiting for application startup.
01:46:06 AM [x59gj] INFO: Application startup complete.
01:46:06 AM [x59gj] INFO: Uvicorn running on http://0.0.0.0:10000 (Press CTRL+C to quit)
01:46:07 AM [x59gj] INFO: 127.0.0.1:36234 - "HEAD / HTTP/1.1" 405 Method Not Allowed
01:46:08 AM ==> Your service is live 🎉
01:46:08 AM ==>
01:46:08 AM ==>
01:46:08 AM ==> Available at your primary URL https://projet-neovolt-5.onrender.com
01:46:08 AM ==>
01:46:08 AM ==>
01:46:08 AM [x59gj] INFO: 34.168.50.200:0 - "GET / HTTP/1.1" 200 OK
```

1

2

3

4

5

6

7

8

Volet E: Cybersécurité et Infrastructures Critiques

Analyses des risques

1

2

3

4

5

6

7

8

Catégorie	Éléments
Actifs critiques	Données de consommation, données clients, compteurs connectés, plateforme d'analyse, fichiers CSV
Menaces	Fuite de données, accès non autorisé, fraude, attaques IoT, indisponibilité système
Vulnérabilités	Données non chiffrées, pas de contrôle d'accès, absence de logs, communications non sécurisées
Criticité	● Données clients & compteurs ● Plateforme ● Dashboard

Audit de securite & securisation

1

2

3

4

5

6

7

8

Faiblesses identifiées

- Stockage en clair (CSV)
- Pas d'authentification
- Pas de chiffrement
- Accès libre aux fichiers
- Pas de traçabilité

Audit de securite & securisation

1

2

3

4

5

6

7

8

Recommandation

Priorité	Recommandation
Haute	• Contrôle d'accès (rôles utilisateurs) • Chiffrement des données sensibles • Protection des données clients
Moyenne	• Mise en place de logs • Validation des données
Faible	• Séparation test / production • Amélioration du stockage

Détection, réponse & conformité

1

2

3

4

5

6

7

8

Catégorie	Éléments
Supervision (SIEM/SOC)	Surveillance connexions, accès données, anomalies, comportements suspects
Règles de détection	Échecs répétés, variation consommation, accès suspects, modification donnée
Réponse à incident	Détection → Isolation → Analyse → Correction → Restauration → Documentation
Continuité & RGPD	Sauvegardes, restauration rapide, minimisation données, anonymisation, accès limité



Merci

1

2

3

4

5

6

7

8